



奇異值分解(SVD)原理與在降維中的應用

其他 · 發表 2018-12-20

奇異值分解(Singular Value Decomposition，以下簡稱SVD)是在機器學習領域廣泛應用的演算法，它不光可以用於降維演算法中的特徵分解，還可以用於推薦系統，以及自然語言處理等領域。是很多機器學習演算法的基石。本文就對SVD的原理做一個總結，並討論在在PCA降維演算法中是如何運用運用SVD的。

1. 回顧特徵值和特徵向量

我們首先回顧下特徵值和特徵向量的定義如下：

$$Ax=\lambda x$$

其中A是一個n×n的矩陣，x是一個n維向量，則我們說λ是矩陣A的一個特徵值，而x是矩陣A的特徵值λ所對應的特徵向量。

求出特徵值和特徵向量有什麼好處呢？就是我們可以將矩陣A特徵分解。如果我們求出了矩陣A的n個特徵值λ1≤λ2≤...≤λn,以及這n個特徵值所對應的特徵向量{w1,w2,...wn}，，如果這n個特徵向量線性無關，那麼矩陣A就可以用下式的特徵分解表示：

$$A=W\Sigma W^{-1}$$

其中W是這n個特徵向量所張成的n×n維矩陣，而Σ為這n個特徵值為主對角線的n×n維矩陣。

一般我們會把W的這n個特徵向量標準化，即滿足||wi||2=1, 或者說wTiwi=1，此時W的n個特徵向量為標準正交基，滿足WTW=I，即WT=W-1, 也就是說W為酉矩陣。

這樣我們的特徵分解表示式可以寫成



第十組 分析Mac版本的搜狗輸入法和Mac輸入法（桌面版）

day7-python操作redis、excel

mysql的分頁（不看後悔，一看必懂）

java提標

IFTTT與Google+是什麼 ifttt怎麼玩

MySql何時用MyISAM何時用InnoDB（不看後悔，一看必懂）

ant-design-pro彈出框表單設定預設值

PCI 32 PCI 64和PCI-X，PCI-E圖解差別

java初體驗作業人

張慧穎 廊坊師範學院資訊科技提高班 十四期

$A=W\Sigma W^T$


注意到要進行特徵分解，矩陣**A**必須為方陣。那麼如果**A**不是方陣，即行和列不相同時，我們還可以對矩陣進行分解嗎？答案是可以，此時我們的**SVD**登場了。

2. SVD的定義

SVD也是對矩陣進行分解，但是和特徵分解不同，**SVD**並不要求要分解的矩陣為方陣。假設我們的矩陣**A**是一個**m×n**的矩陣，那麼我們定義矩陣**A**的**SVD**為：

$A=U\Sigma V^T$

其中**U**是一個**m×m**的矩陣，**Σ**是一個**m×n**的矩陣，除了主對角線上的元素以外全為**0**，主對角線上的每個元素都稱為奇異值，**V**是一個**n×n**的矩陣。**U**和**V**都是酉矩陣，即滿足**U^TU=I**,**V^TV=I**。下圖可以很形象的看出上面**SVD**的定義：



那麼我們如何求出**SVD**分解後的**U,Σ,V**這三個矩陣呢？

如果我們將**A**的轉置和**A**做矩陣乘法，那麼會得到**n×n**的一個方陣**ATA**。既然**ATA**是方陣，那麼我們就可以進行特徵分解，得到的特徵值和特徵向量滿足下式：

$(ATA)v_i=\lambda_i v_i$

這樣我們就可以得到矩陣**ATA**的**n**個特徵值和對應的**n**個特徵向量**v**了。將**ATA**的所有特徵向量張成一個**n×n**的矩陣**V**，就是我們**SVD**公式裡面的**V**矩陣了。一般我們將**V**中的每個特徵向量叫做**A**的右奇異向量。

如果我們將**A**和**A**的轉置做矩陣乘法，那麼會得到**m×m**的一個方陣**AAT**。既然**AAT**是方陣，那麼我們就可以進行特徵分解，得到的特徵值和特徵向量滿足下式：

$(AAT)u_i=\lambda_i u_i$

這樣我們就可以得到矩陣**AAT**的**m**個特徵值和對應的**m**個特徵向量**u**了。將**AAT**的所有特徵向量張成一個**m×m**的矩陣**U**，就是我們**SVD**公式裡面的**U**矩陣了。一般我們將**U**中的每個特徵向量叫做**A**的左奇異向量。

U和**V**我們都求出來了，現在就剩下奇異值矩陣**Σ**沒有求出了。由於**Σ**除了對角線上是奇異值其他位置都是**0**，那我們只需要求出每個奇異值**σ**就可以了。

我們注意到:

$A=U\Sigma V^T \Rightarrow AV=U\Sigma V^T V \Rightarrow AV=U\Sigma \Rightarrow A v_i=\sigma_i u_i \Rightarrow \sigma_i=A v_i / u_i$

這樣我們可以求出我們的每個奇異值，進而求出奇異值矩陣Σ。

上面還有一個問題沒有講，就是我們說ATA的特徵向量組成的就是我們SVD中的V矩陣，而AAT的特徵向量組成的就是我們SVD中的U矩陣，這有什麼根據嗎？這個其實很容易證明，我們以V矩陣的證明為例。

$$\mathbf{A}=\mathbf{U}\Sigma\mathbf{V}^T\Rightarrow\mathbf{A}^T=\mathbf{V}\Sigma^T\mathbf{U}^T\Rightarrow\mathbf{A}^T\mathbf{A}=\mathbf{V}\Sigma^T\mathbf{U}^T\mathbf{U}\Sigma\mathbf{V}^T=\mathbf{V}\Sigma^2\mathbf{V}^T$$

上式證明使用了:UTU=I,ΣTΣ=Σ2。可以看出ATA的特徵向量組成的的確就是我們SVD中的V矩陣。類似的方法可以得到AAT的特徵向量組成的就是我們SVD中的U矩陣。

進一步我們還可以看出我們的特徵值矩陣等於奇異值矩陣的平方，也就是說特徵值和奇異值滿足如下關係：

$$\sigma_i=\lambda_i^{1/2}$$

這樣也就是說，我們可以不用σi=Avi/ui來計算奇異值，也可以通過求出ATA的特徵值取平方根來求奇異值。

3. SVD計算舉例

裡我們用一個簡單的例子來說明矩陣是如何進行奇異值分解的。我們的矩陣A定義為：

$$\mathbf{A}=\begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix}$$

我們首先求出ATA和AAT

$$\mathbf{A}^T\mathbf{A}=\begin{pmatrix} 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix}\begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix}=\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$
$$\mathbf{A}\mathbf{A}^T=\begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix}\begin{pmatrix} 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix}=\begin{pmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 1 \end{pmatrix}$$

進而求出ATA的特徵值和特徵向量：

$$\lambda_1=3; \mathbf{v}_1=\begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}; \lambda_2=1; \mathbf{v}_2=\begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

接著求AAT的特徵值和特徵向量：

$$\lambda_1=3; \mathbf{u}_1=\begin{pmatrix} 1/\sqrt{6} \\ 2/\sqrt{6} \\ 1/\sqrt{6} \end{pmatrix}; \lambda_2=1; \mathbf{u}_2=\begin{pmatrix} 1/\sqrt{2} \\ 0 \\ -1/\sqrt{2} \end{pmatrix}; \lambda_3=0; \mathbf{u}_3=\begin{pmatrix} 1/\sqrt{3} \\ -1/\sqrt{3} \\ 1/\sqrt{3} \end{pmatrix}$$

利用Avi=σiui,i=1,2求奇異值：

$$\begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} = \sigma_1 \begin{pmatrix} 1/\sqrt{6} \\ 2/\sqrt{6} \\ 1/\sqrt{6} \end{pmatrix} \Rightarrow \sigma_1 = \sqrt{3}$$
$$\begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} = \sigma_2 \begin{pmatrix} 1/\sqrt{2} \\ 0 \\ -1/\sqrt{2} \end{pmatrix} \Rightarrow \sigma_2 = 1$$

當然，我們也可以用 $\sigma_i = \lambda_i - \frac{1}{\lambda_i}$ 直接求出奇異值為 $\sqrt{3}$ 和1。

最終得到A的奇異值分解為：

$$A = U \Sigma V^T = \begin{pmatrix} 1/\sqrt{6} & 1/\sqrt{2} & 1/\sqrt{3} \\ 2/\sqrt{6} & 0 & -1/\sqrt{3} \\ 1/\sqrt{6} & -1/\sqrt{2} & 1/\sqrt{3} \end{pmatrix} \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$


4. SVD的一些性質

上面幾節我們對SVD的定義和計算做了詳細的描述，似乎看不出我們費這麼大的力氣做SVD有什麼好處。那麼SVD有什麼重要的性質值得我們注意呢？

對於奇異值,它跟我們特徵分解中的特徵值類似，在奇異值矩陣中也是按照從大到小排列，而且奇異值的減少特別的快，在很多情況下，前10%甚至1%的奇異值的和就佔了全部的奇異值之和的99%以上的比例。也就是說，我們也可以用最大的k個的奇異值和對應的左右奇異向量來近似描述矩陣。也就是說：

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V_{n \times n} \approx U_{m \times k} \Sigma_{k \times k} V_{k \times n}$$

其中k要比n小很多，也就是一個大的矩陣A可以用三個小的矩陣 $U_{m \times k}, \Sigma_{k \times k}, V_{k \times n}$ 來表示。如下圖所示，現在我們的矩陣A只需要灰色的部分的三個小矩陣就可以近似描述了。



由於這個重要的性質，SVD可以用於PCA降維，來做資料壓縮和去噪。也可以用於推薦演算法，將使用者和喜好對應的矩陣做特徵分解，進而得到隱含的使用者需求來做推薦。同時也可以用於NLP中的演算法，比如潛在語義索引（LSI）。下面我們就對SVD用於PCA降維做一個介紹。

5. SVD用於PCA

在主成分分析（PCA）原理總結中，我們講到要用PCA降維，需要找到樣本協方差矩陣 XX^T 的最大的d個特徵向量，然後用這最大的d個特徵向量張成的矩陣來做低維投影降維。可以看出，在這個過程中需要先求出協方差矩陣 XX^T ，當樣本數多樣本特徵數也多的時候，這個計算量是很大的。

注意到我們的SVD也可以得到協方差矩陣 XX^T 最大的d個特徵向量張成的矩陣，但是SVD有個好處，有一些SVD的實現演算法可

以不求先求出協方差矩陣 $\mathbf{X}\mathbf{X}^T$ ，也能求出我們的右奇異矩陣 \mathbf{V} 。也就是說，我們的PCA演算法可以不用做特徵分解，而是做SVD來完成。這個方法在樣本量很大的時候很有效。實際上，scikit-learn的PCA演算法的背後真正的實現就是用的SVD，而不是我們認為的暴力特徵分解。

另一方面，注意到PCA僅僅使用了我們SVD的右奇異矩陣，沒有使用左奇異矩陣，那麼左奇異矩陣有什麼用呢？

假設我們的樣本是 $m \times n$ 的矩陣 \mathbf{X} ，如果我們通過SVD找到了矩陣 $\mathbf{X}\mathbf{X}^T$ 最大的 d 個特徵向量張成的 $m \times d$ 維矩陣 \mathbf{U} ，則我們如果進行如下處理：

$$\mathbf{X}'_{d \times n} = \mathbf{U}^T \mathbf{X}_{m \times n}$$

可以得到一個 $d \times n$ 的矩陣 \mathbf{X}' ，這個矩陣和我們原來的 $m \times n$ 維樣本矩陣 \mathbf{X} 相比，行數從 m 減到了 k ，可見對行數進行了壓縮。也就是說，左奇異矩陣可以用於行數的壓縮。相對的，右奇異矩陣可以用於列數即特徵維度的壓縮，也就是我們的PCA降維。

6. SVD小結

SVD作為一個很基本的演算法，在很多機器學習演算法中都有它的身影，特別是在現在的大資料時代，由於SVD可以實現並行化，因此更是大展身手。SVD的原理不難，只要有基本的線性代數知識就可以理解，實現也很簡單因此值得仔細的研究。當然，SVD的缺點是分解出的矩陣解釋性往往不強，有點黑盒子的味道，不過這不影響它的使用。



標籤：

👍 您可能也會喜歡...

- 奇異值分解(SVD)原理與在降維中的應用
- 機器學習實戰（Machine Learning in Action）學習筆記——10.奇異值分解(SVD)原理、基於協同過濾的推薦引擎、數據降維
- 奇異值分解(SVD)原理詳解及推導
- 奇異值分解(SVD)原理詳解
- 差分陣列原理與其字首和的應用

- 奇異值分解(SVD)原理詳解及推導（轉）
- 機器學習實戰（Machine Learning in Action）學習筆記——10.奇異值分解(SVD)原理、基於協同過濾的推薦引擎、資料降維
- 奇異值分解（SVD）原理
- 奇異值分解(SVD)原理及應用
- B樹和B+樹原理及在索引中的應用

奇異值分解SVD計算原理及JAVA程式碼

矩陣的奇異值分解（SVD）（理論）
奇異值的物理意義是什麼？強大的矩陣
奇異值分解(SVD)及其應用

[數學] 奇異值分解SVD的理解與應用

數學基礎系列(六)---特徵值分解和奇異值分解(SVD)

首頁
Python教學



ITREAD01.COM © 2018. 版權所有。